

지능형 모터 5조

# AI를 활용한 PMSM 제어

함나경 이진우 심광선 문준혁 김은영 강지희

# Contents

- 01 ━━━━━━━━ 가설
- 02 ━━━━━━━━ 전류 PI제어
- 03 ━━━━━━━━ 전류 RL제어
- 04 ━━━━━━━━ PI vs RL
- 05 ━━━━━━━━ 속도 RL제어

## 팀원 설명



함나경



문준혁



김은영



심광선



이진우



강지희

알고리즘 검증,  
하드웨어 적용

PI 제어 모델  
튜닝 및 분석

강화학습 모델  
설계 및 분석

프로젝트 기획,  
강건성 평가

프로젝트 기획,  
속도 제어

강화학습 모델  
자료 조사

## 가설

“강화학습이 더 강건하다?”



유동성

세탁물의 양에 따라  
달라지는 부하

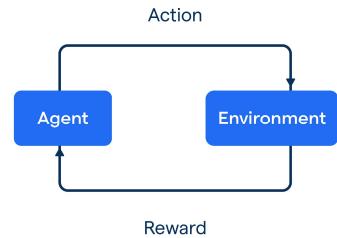


비선형성

움직이는 옷 뭉치에  
따라 달라지는 부하

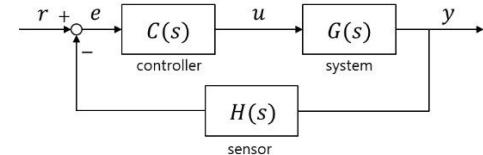
# 가설

## 강화학습



1. 에이전트가 환경과의 상호 작용을 통해 최적의 정책을 학습하기 때문에, **부하 변화**와 같은 동적인 상황에서도 효과적인 제어가 가능할 것이다.
2. 강화학습은 시스템의 정확한 수학적 모델 없이도 환경과의 상호작용을 통해 최적의 제어 정책을 학습할 수 있다. 이는 **비선형적인 부하 특성을** 가진 시스템에서도 효과적으로 적용된다.

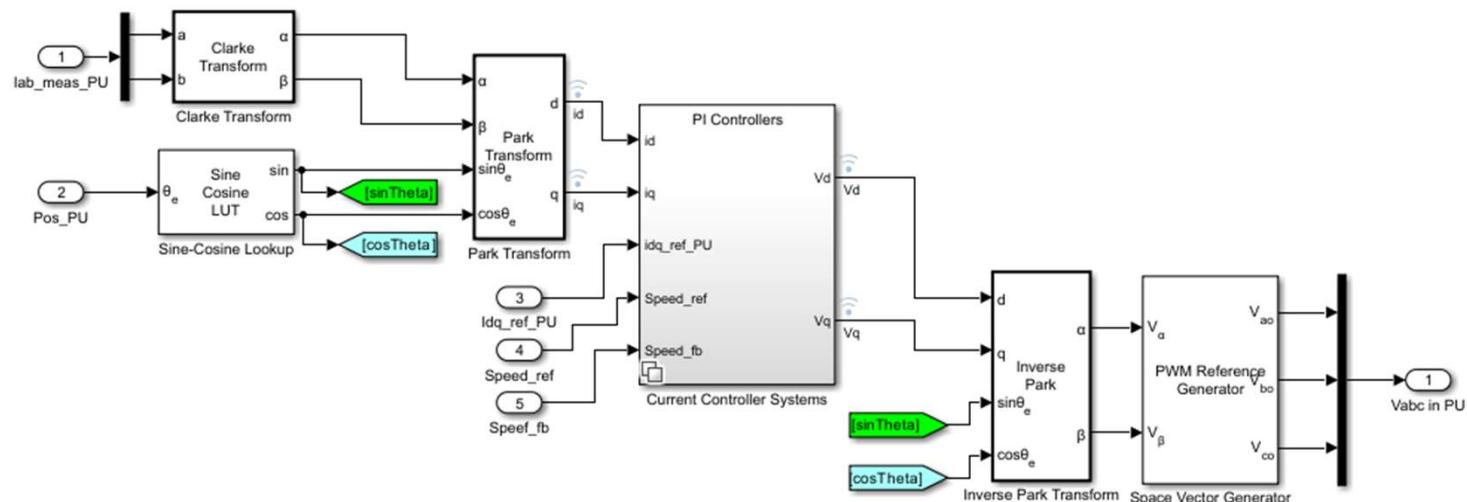
## PID 제어



VS

1. PID 제어에는 Gain 간의 Trade-off가 존재한다. 만약 부하가 유동적으로 변화하는 경우, 하나의 고정된 Gain만으로는 정확한 속도 추종이 어려울 수 있다.
2. PID 제어기는 선형 시스템의 선형성을 가정하며, 자체적으로 선형 연산을 수행하여 중첩의 원리 (superposition principle)를 만족한다.

# 전류 PI 제어



## FOC 제어

FOC 제어는 3상 전류를 Park-Clarke 변환을 거쳐 d축과 q축 성분으로 변환하여 제어하는 벡터 제어 기법이다.

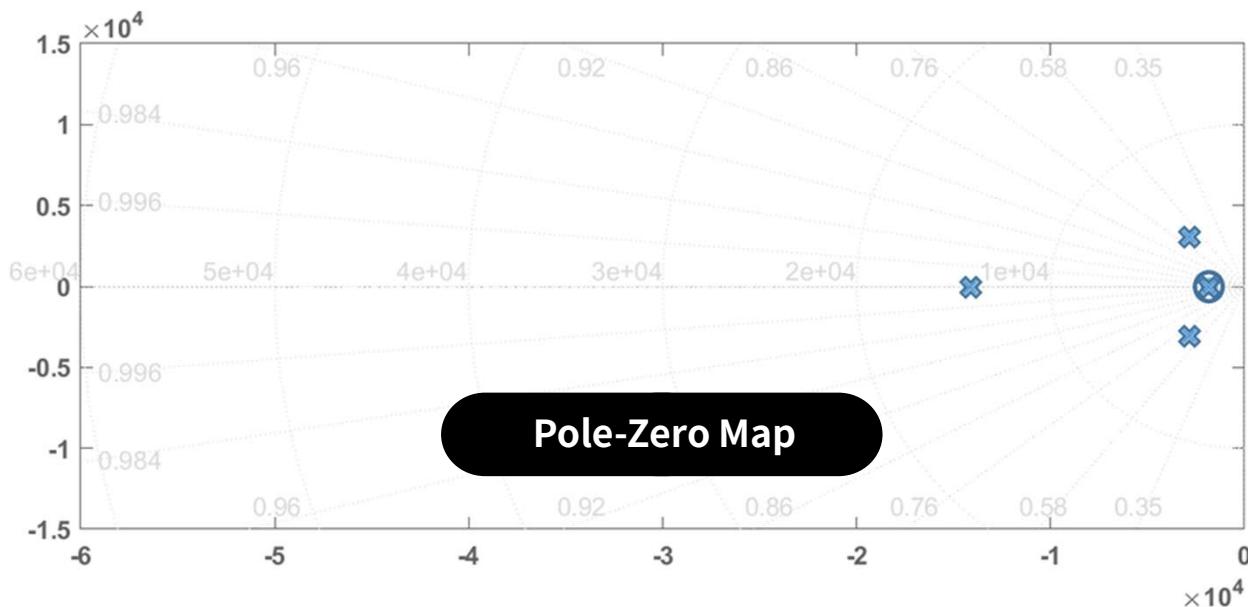
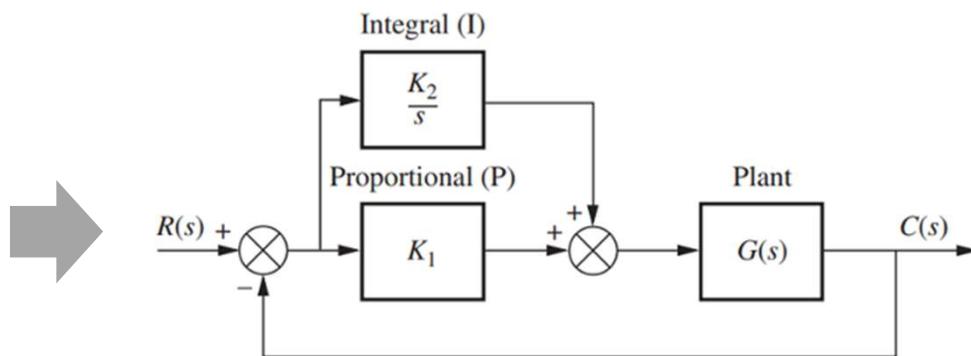
MATLAB : Field-Oriented Control of PMSM Using Reinforcement Learning

# 전류 PI 제어

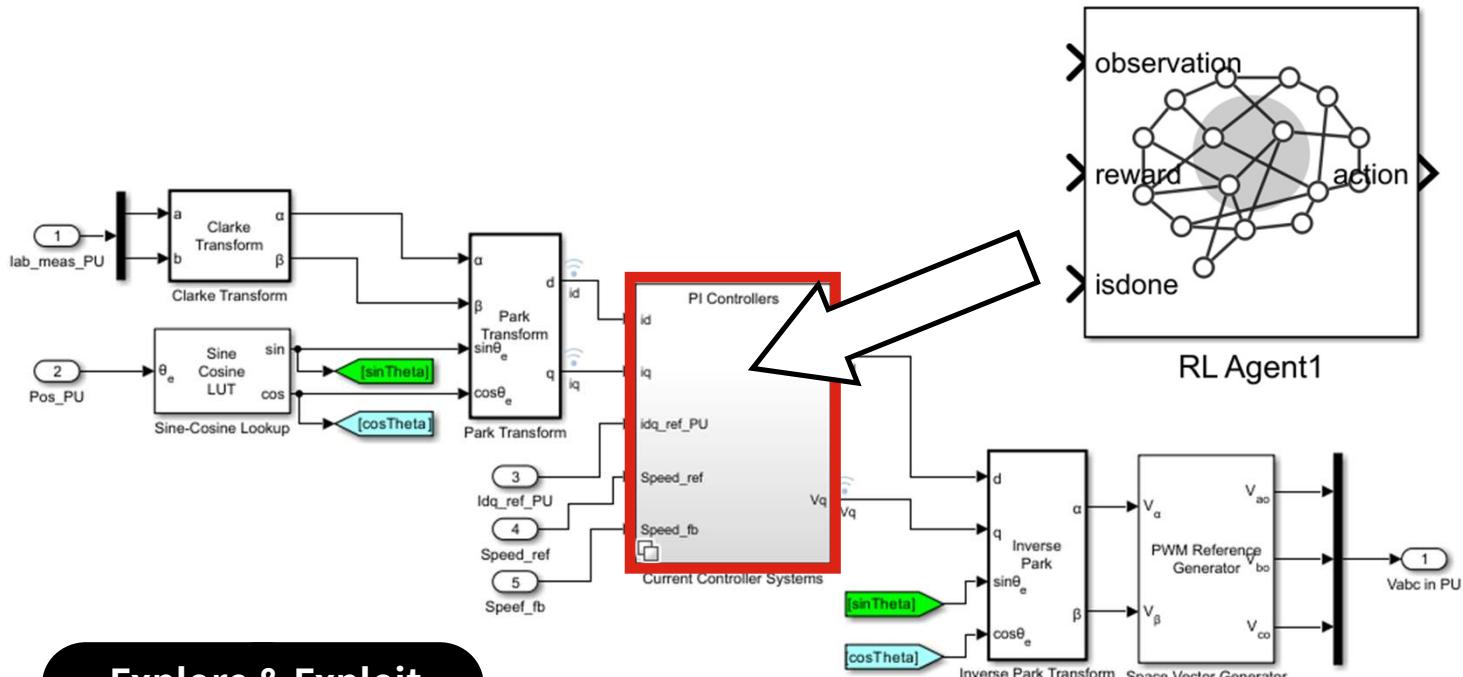
전류 개인 속도 개인

$$K_p = L \cdot W_{cc}$$
$$K_i = R \cdot W_{cc}$$

$$K_{ps} = J \cdot W_{sc}$$
$$K_{is} = 0.2 \cdot K_{ps} \cdot W_{sc}$$



# 전류 RL 제어



**Explore & Exploit**

학습 초기에 다양한 행동을 시도 하며 Q함수를 학습한다.  
또한, 결정론적 정책에 노이즈 추가한다.

$$a' = \pi(s) + \text{noise} \quad Q(s, a) = r_t + \gamma \cdot \max_{a'} Q(s', a')$$

학습이 진행되면 Q 함수가 정확해지면  
 $Q(s, a)$ 값이 최대가 되는 행동을 선택한다.

$$a = \operatorname{argmax}_a Q(s, a)$$

MATLAB : Field-Oriented Control of PMSM Using Reinforcement Learning

# 전류 RL 제어

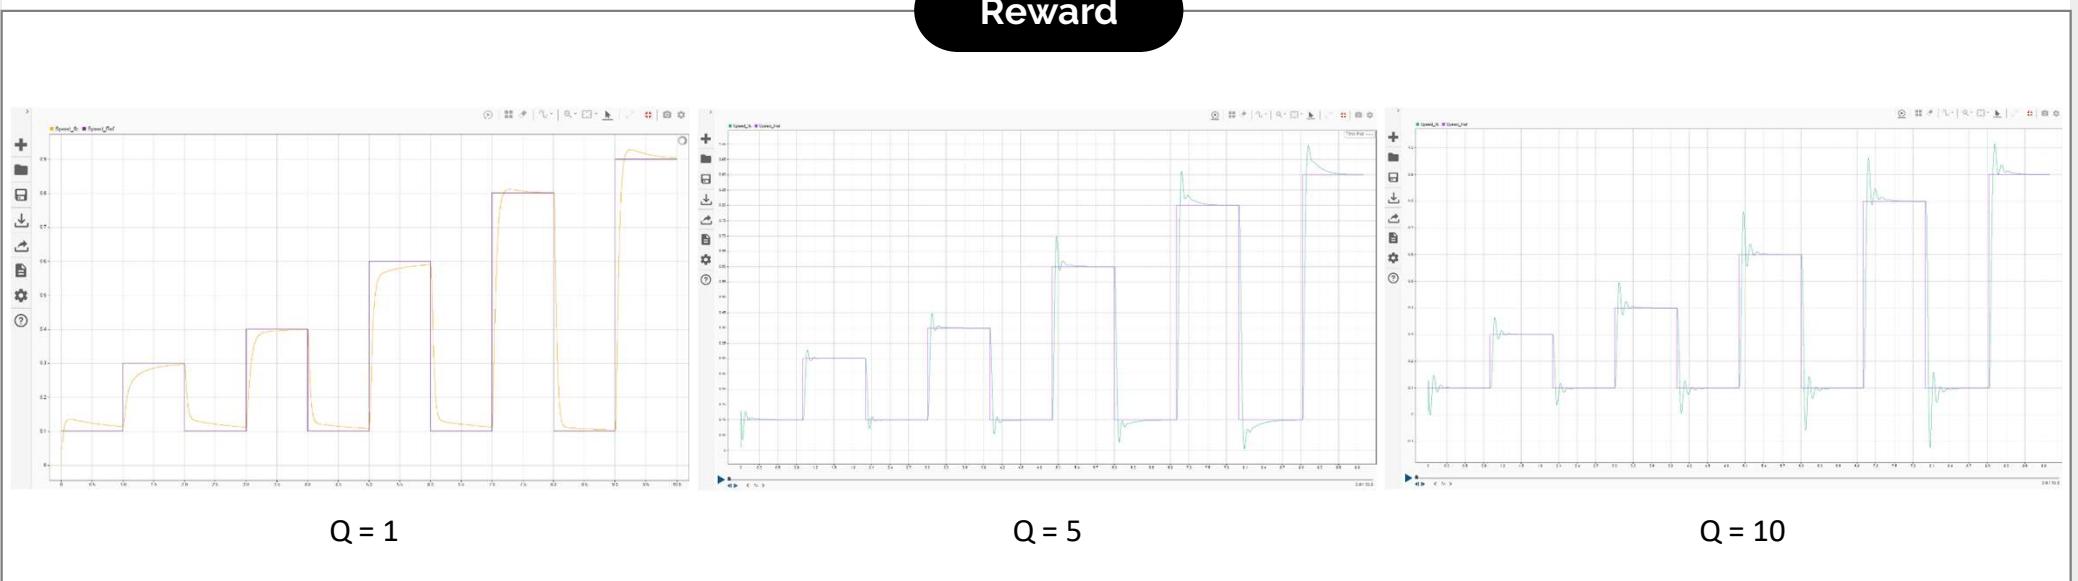
## Reward

$$r_t = - \left[ \underbrace{Q_1 \cdot i_{d,\text{error}}^2}_{\text{d축 전류 에러 패널티}} + \underbrace{Q_2 \cdot i_{q,\text{error}}^2}_{\text{q축 전류 에러 패널티}} + \underbrace{R \cdot \sum_j u_j^{t-12}}_{\text{행동 에너지 패널티}} \right] - \underbrace{100 \cdot d}_{\text{조기 종료 패널티}}$$

Discount Factor( $\gamma$ )	0.995
탐색 노이즈( $\sigma$ )	0.05
상태 공간	Ref. 속도, Mes. 속도, d/q축 전류, d/q축 전류 에러, 에러 적분
행동 공간	d/q축 전압

# 전류 RL 제어

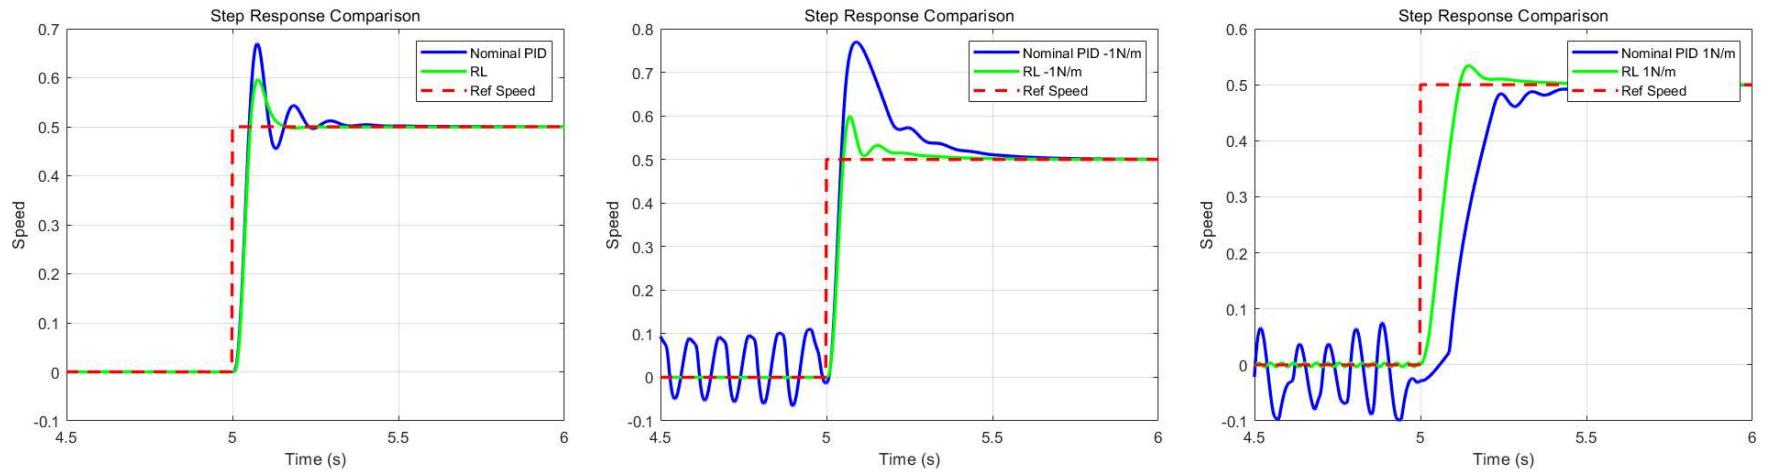
## Reward



•  
•  
•

Teknic 모터의 최적 리워드를 찾기 위해 다양한 조건에서 학습을  
진행했다.

## PI vs RL



PID No Load	RL No Load	PID Load +	RL Load +	PID Load -	RL Load -
Overshoot (%)	33.95	<b>19.30</b>	53.92	<b>19.85</b>	<b>0.01</b>
Rise Time (s)	<b>0.0460</b>	0.0480	<b>0.0260</b>	0.0360	<b>0.0784</b>
Settling Time (s)	0.3100	<b>0.1320</b>	0.5120	<b>0.2740</b>	<b>0.2490</b>

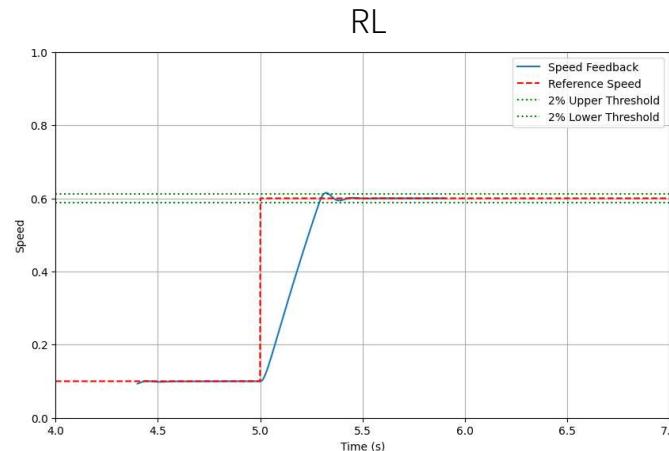
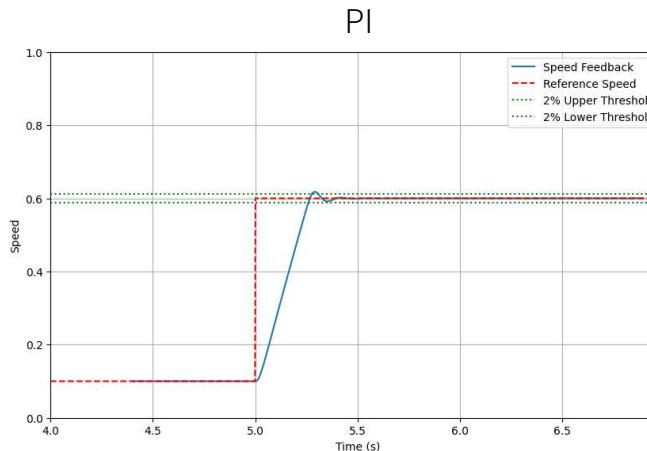
## **PI vs RL**



$$I = \int r^2 dm = \int \rho(\mathbf{r}) r^2 dV$$

**관성 모멘트 J :** 물체가 회전 운동을 유지하려는 정도

세탁물이 많아질수록, 또한 세탁물이 회전에 의해 바깥으로 밀려날수록 J가 증가한다. 이처럼 증가한 J를 모사하기 위해  $J=0.001\text{kg}\cdot\text{m}^2$ 로 증가시켰다. 이로 인해 이전과 달리 변화가 쉽게 나타나지 않아서, 앞서 관찰되던 차이가 보이지 않는다.



# PI vs RL - 강건성

## 목표

- 생산 과정에 의한 모터 파라미터 편차에 따른 결과를 본다.
- RL이 PI 제어기 만큼 강건한지 확인한다.

## 실험 방법

### 1. 세탁물의 양에 따른 강건성

Target 세탁물 양에서 학습된 두 모델(RL, PI)를 다른 세탁물의 양에서 실험

### 2. 모터 파라미터 변동폭에 따른 강건성

일부 모터 파라미터에  $\pm 10\%$ ,  $\pm 20\%$  변동을 주어 강건성을 확인

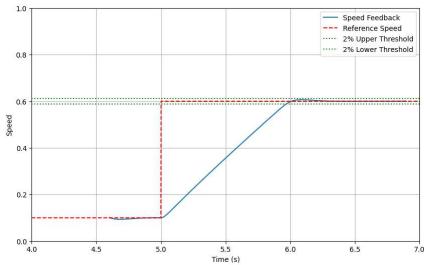
실험번호	저항(Rs)	인덕턴스(Ldq)	FluxPM	Inertia(J)	Overshoot	Rising Time	Settling Time(5%)	Peak Time	Steady State Error
1	0.9	0.9	0.9	0.9					
2	0.9	1	1	1					
3	0.9	1.1	1.1	1.1					
4	1	0.9	1	1.1					
5	1	1	1.1	0.9					
6	1	1.1	0.9	1					
7	1.1	0.9	1.1	1					
8	1.1	1	0.9	1.1					
9	1.1	1.1	1	0.9					

L9 직교배열: 4인자 3수준 5반응

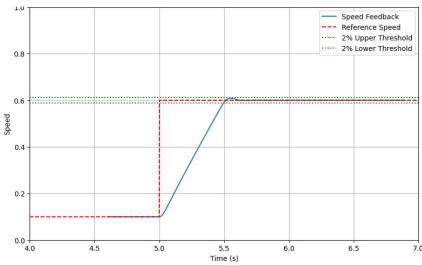
## PI vs RL - 세탁물의 양에 따른 강건성

세탁물 증가(관성 모멘트 증가)

4J

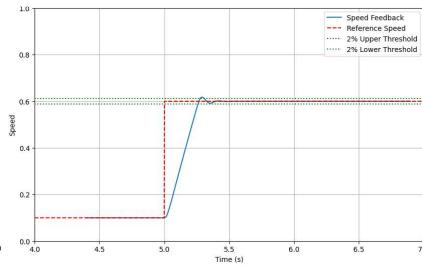


2J

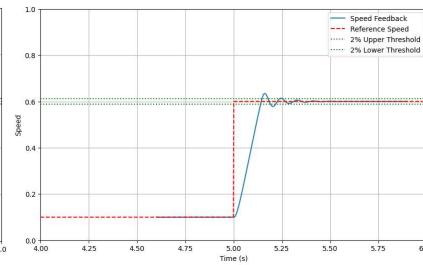


Target 세탁물 중량

J (Baseline)



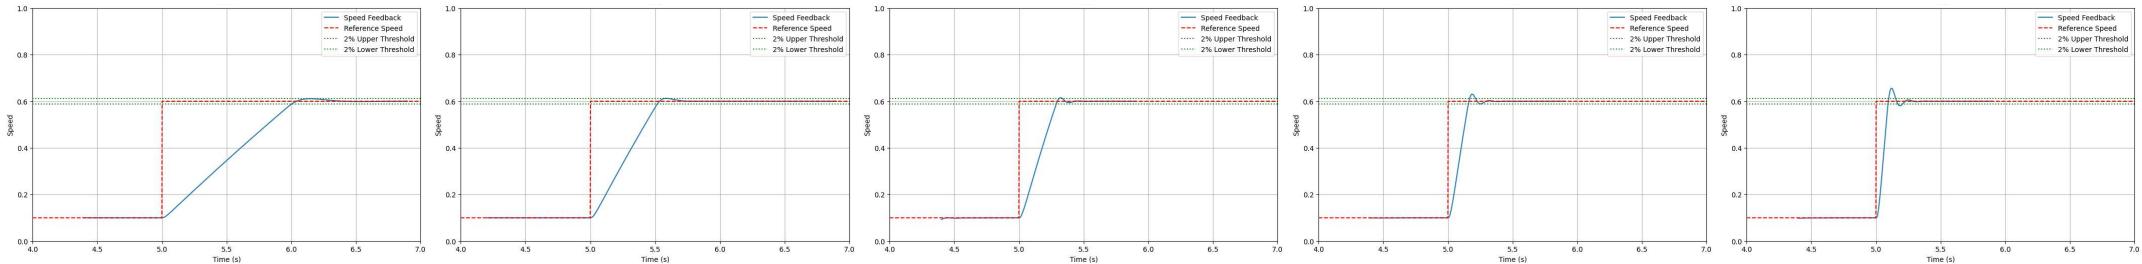
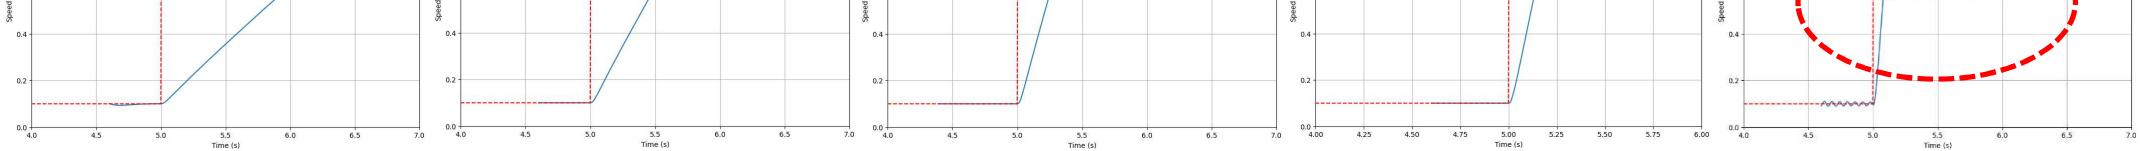
0.5J



0.25J

세탁물 감소(관성 모멘트 감소)

PI



동일하게 안정적인 변화

PI의 경우, Oscillation 발생

# PI 결과



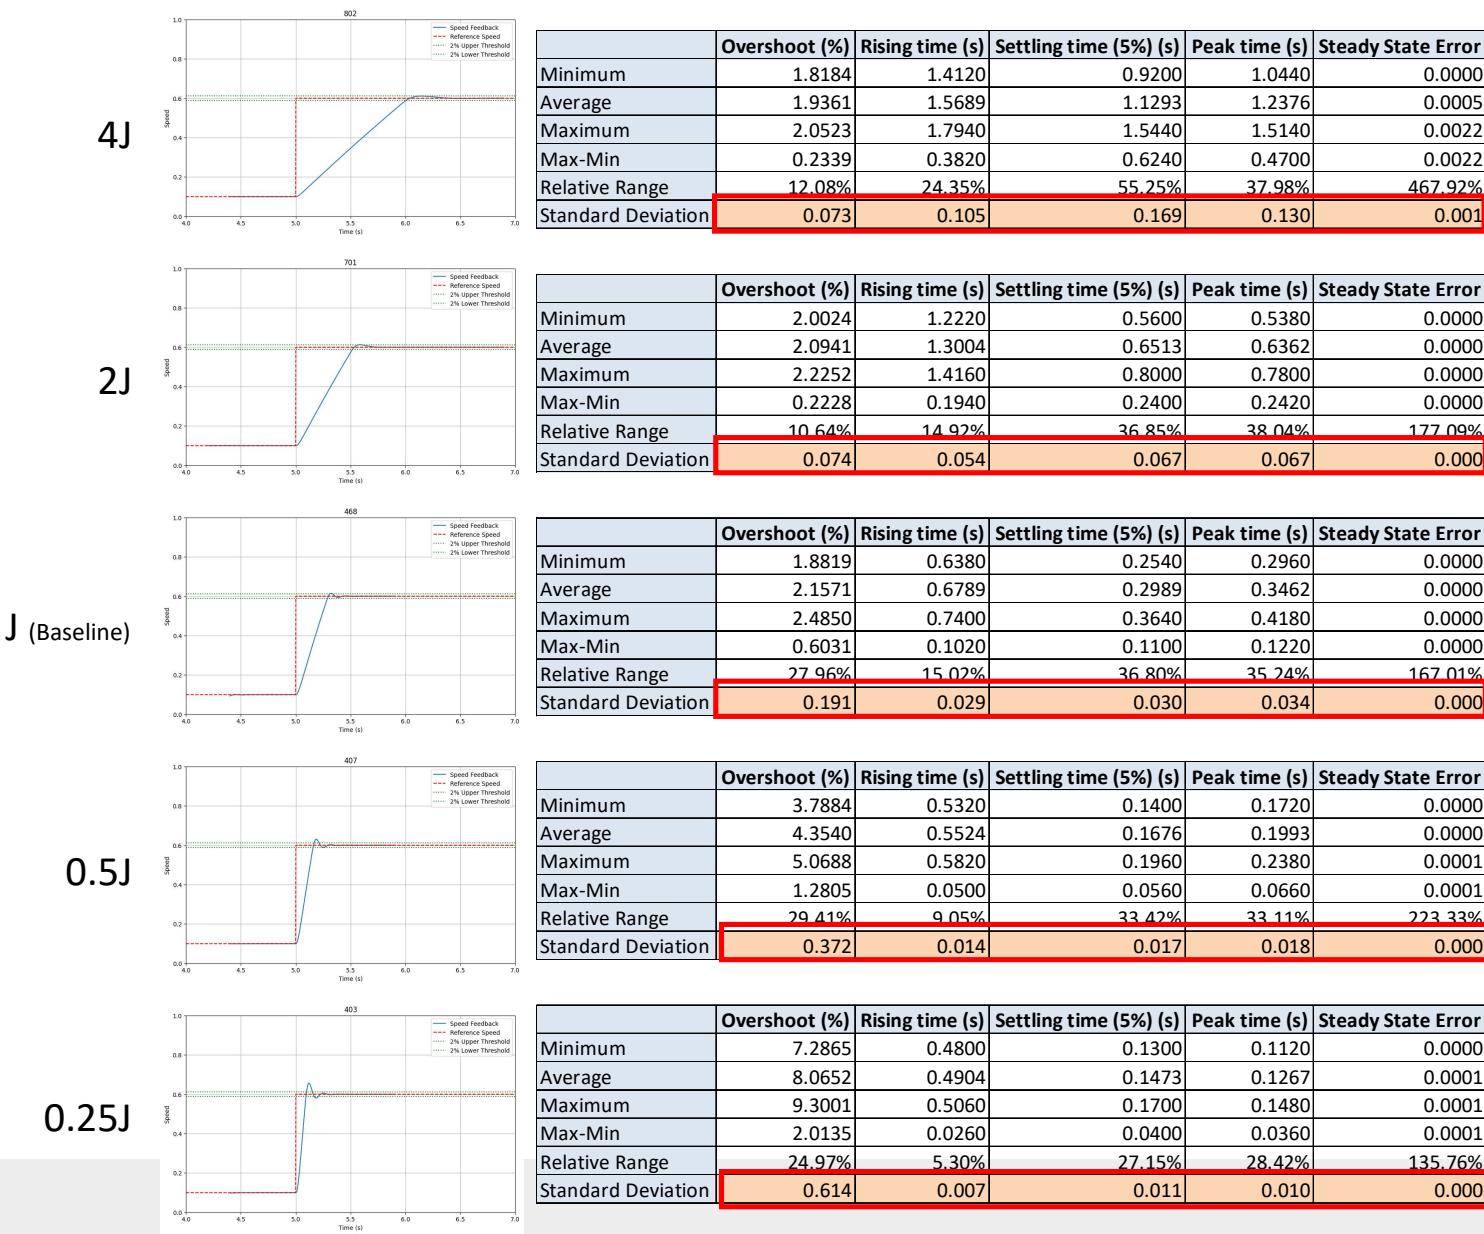
**표준편차 감소**  
(모터 파라미터 변동에 강건)

Target J 보다 클수록  
모터 파라미터에 둔감하며,  
작을수록 모터 파라미터에  
민감하다.

**표준편차 증가**  
(모터 파라미터 변동에 예민)

SAMSUNG

GIST



표준편차 감소  
(모터 파라미터 변동에 강건)

Target J 보다 클수록  
모터 파라미터에 둔감하며,  
작을수록 모터 파라미터에  
민감하다.

표준편차 증가  
(모터 파라미터 변동에 예민)

## PI vs RL - 모터 파라미터 변동폭에 따른 강건성

파라미터 10% 변동

PI

	Overshoot (%)	Rising time (s)	Settling time (5%) (s)	Peak time (s)	Steady State Error
Minimum	1.1290	1.5640	0.8720	0.9720	0.0000
Average	1.2672	1.7158	1.0376	1.1604	0.0000
Maximum	1.3531	1.9260	1.2720	1.4200	0.0003
Max-Min	0.2242	0.3620	0.4000	0.4480	0.0003
Relative Range	17.69%	21.10%	38.55%	38.61%	762.89%
Standard Deviation	0.068	0.099	0.109	0.122	0.000

RL

	Overshoot (%)	Rising time (s)	Settling time (5%) (s)	Peak time (s)	Steady State Error
Minimum	1.8184	1.4120	0.9200	1.0440	0.0000
Average	1.9361	1.5689	1.1293	1.2376	0.0005
Maximum	2.0523	1.7940	1.5440	1.5140	0.0022
Max-Min	0.2339	0.3820	0.6240	0.4700	0.0022
Relative Range	12.08%	24.35%	55.25%	37.98%	467.92%
Standard Deviation	0.073	0.105	0.169	0.130	0.001

RL은 10% 모터 파라미터 변동에 대하여 PI 동등한 수준으로 강건하다.

PI

파라미터 20% 변동

	Overshoot (%)	Rising time (s)	Settling time (5%) (s)	Peak time (s)	Steady State Error
Minimum	1.7456	0.5800	0.1940	0.2300	0.0000
Average	2.5527	0.6542	0.2733	0.3189	0.0000
Maximum	3.1639	0.7660	0.3940	0.4560	0.0000
Max-Min	1.4183	0.1860	0.2000	0.2260	0.0000
Relative Range	55.56%	28.43%	73.17%	70.87%	190.78%
Standard Deviation	0.454	0.051	0.055	0.062	0.000

RL

	Overshoot (%)	Rising time (s)	Settling time (5%) (s)	Peak time (s)	Steady State Error
Minimum	2.6075	0.5920	0.2080	0.2500	0.0000
Average	3.3177	0.6689	0.2887	0.3429	0.0000
Maximum	4.0514	0.7960	0.4240	0.5020	0.0000
Max-Min	1.4439	0.2040	0.2160	0.2520	0.0000
Relative Range	43.52%	30.50%	74.83%	73.49%	217.10%
Standard Deviation	0.465	0.057	0.061	0.070	0.000

학습하지 않은 영역에서 20% 모터 파라미터 변동에 대해서도 RL은 PI만큼 강건하다.

# PI vs RL - 변동 학습

## 변동 미학습

	Overshoot (%)	Rising time (s)	Settling time (5%) (s)	Peak time (s)	Steady State Error
Minimum	1.8819	0.6380	-1.7460	-1.7040	0.0000
Average	2.1571	0.6789	-1.7011	-1.6538	0.0000
Maximum	2.4850	0.7400	-1.6360	-1.5820	0.0000
Max-Min	0.6031	0.1020	0.1100	0.1220	0.0000
Relative Range	27.96%	15.02%	-6.47%	-7.38%	167.01%
Standard Deviation	0.191	0.029	0.030	0.034	0.000

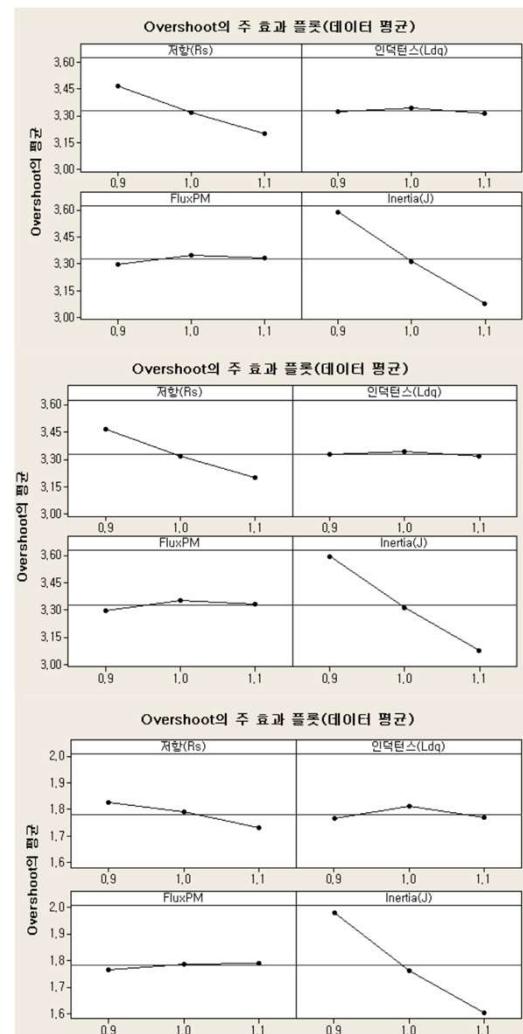
## 파라미터(J) 변동 학습

	Overshoot (%)	Rising time (s)	Settling time (5%) (s)	Peak time (s)	Steady State Error
Minimum	2.9341	0.6260	0.2420	0.2880	0.0000
Average	3.3273	0.6647	0.2829	0.3362	0.0000
Maximum	3.6992	0.7220	0.3440	0.4080	0.0000
Max-Min	0.7652	0.0960	0.1020	0.1200	0.0000
Relative Range	23.00%	14.44%	36.06%	35.69%	283.58%
Standard Deviation	0.239	0.027	0.028	0.033	0.000

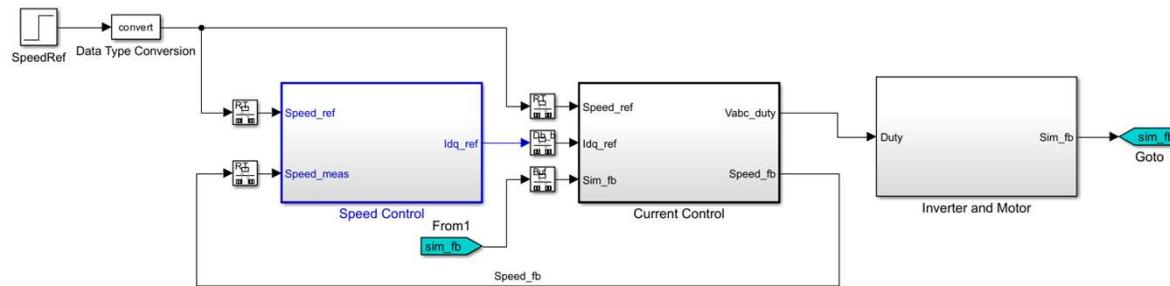
## 파라미터(fluxPM) 변동 학습

	Overshoot (%)	Rising time (s)	Settling time (5%) (s)	Peak time (s)	Steady State Error
Minimum	1.5687	0.7260	0.3480	0.4000	0.0000
Average	1.7820	0.7878	0.4140	0.4751	0.0000
Maximum	2.0278	0.8680	0.4980	0.5720	0.0001
Max-Min	0.4591	0.1420	0.1500	0.1720	0.0001
Relative Range	25.76%	18.03%	36.23%	36.20%	253.37%
Standard Deviation	0.161	0.040	0.042	0.048	0.000

학습 과정에 -10, -5, 0, 5, 10%로 J or fluxPM0| 변동하였을 때를 추가하였으나, 강건성이 생기지는 않았다.



## 속도 RL 제어



$$v_d = Ri_d + L \frac{di_d}{dt} - \omega L i_q \quad (1)$$

$$v_q = Ri_q + L \frac{di_q}{dt} + \omega L i_d + e_q$$

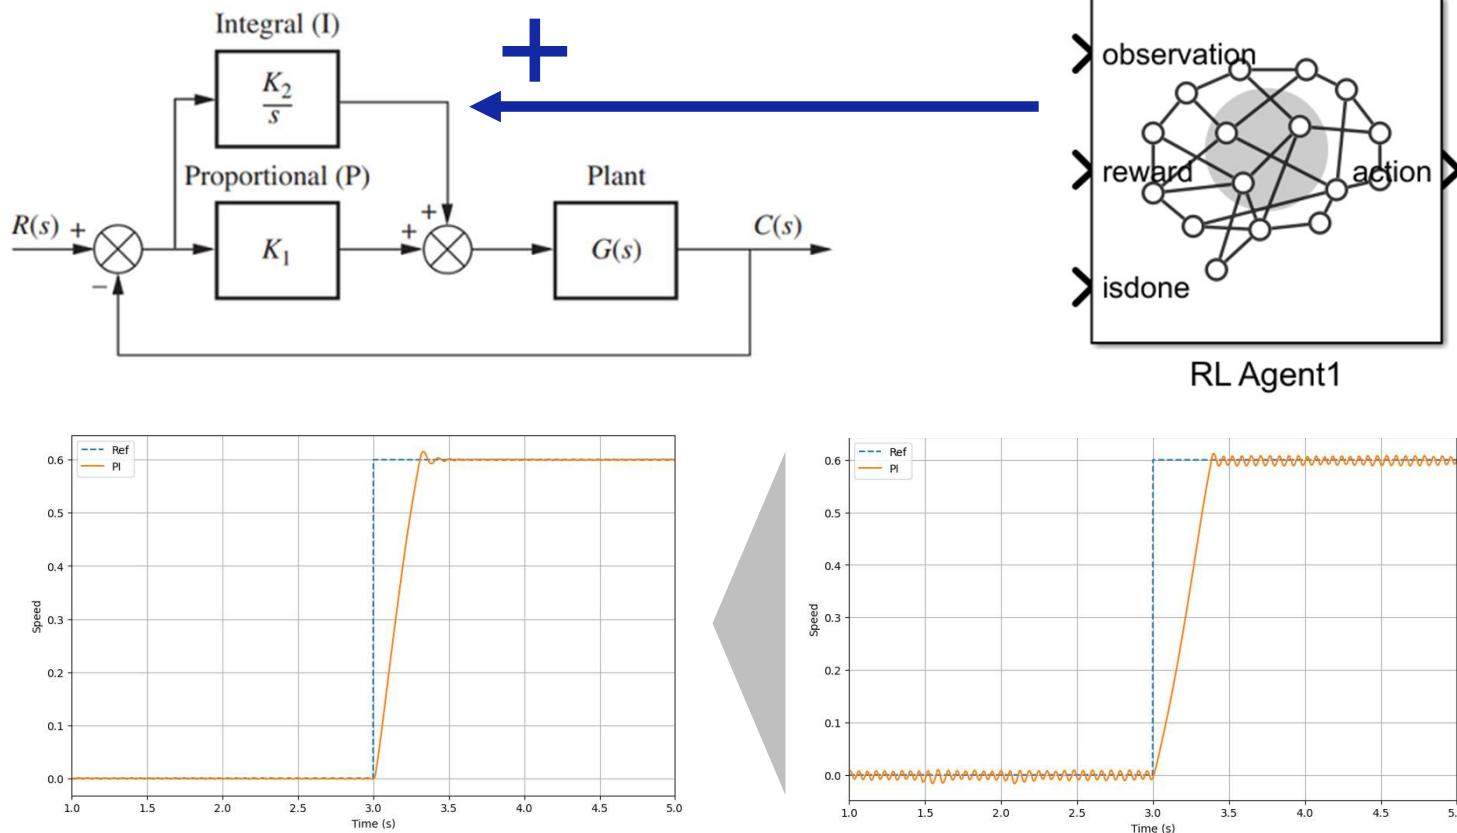
$$T_e = J \frac{d\omega}{dt} + B\omega + T_L \quad (2)$$

전류 제어기에서는 (1) 전류, 전압 지령과 같은 전기적 특성을 다룬다. 반면, (2)에서 표현된  $J$ ,  $B$ ,  $T_L$ 과 같은 외부 부하 특성을 다루기 위해서는 속도 제어기를 강화학습으로 대체하는 것이 더 유리할 수 있다.

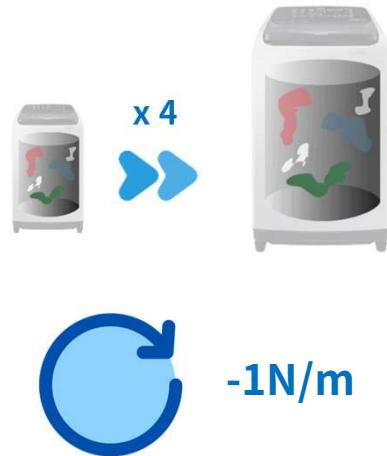
상태 공간	Ref. 속도, Mes. 속도, $f(e)$
행동 공간	q축 전류

$$f(e) = \begin{cases} -1 & \text{if } e > 0 \\ 1 & \text{if } e < 0 \end{cases}$$

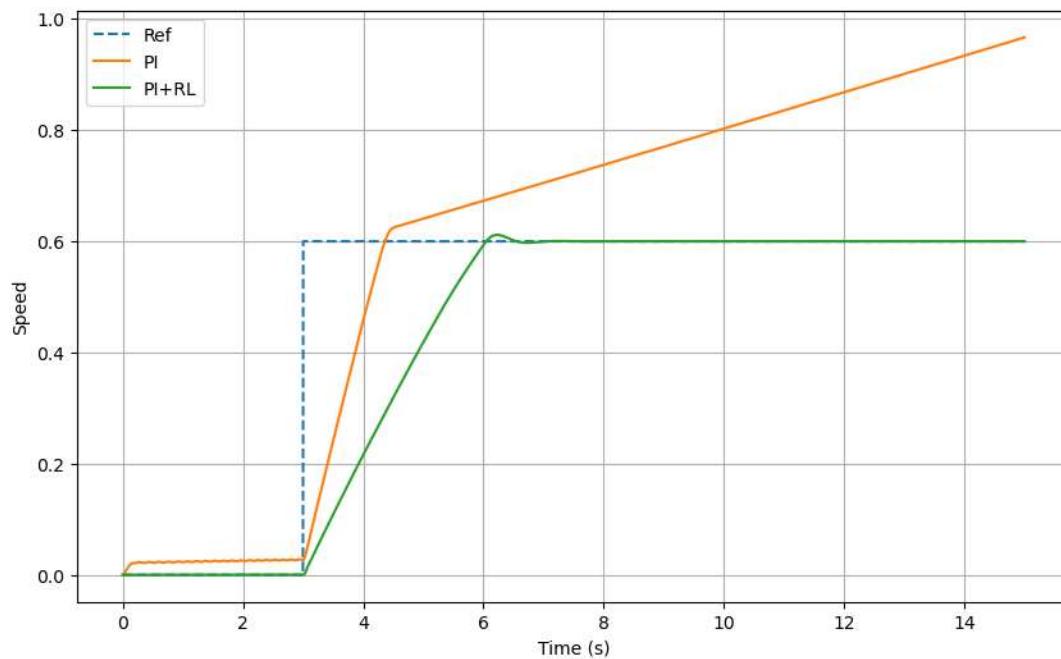
# 속도 RL 제어



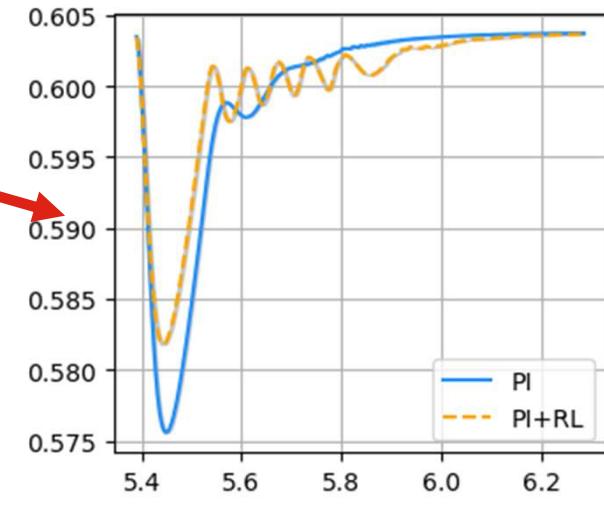
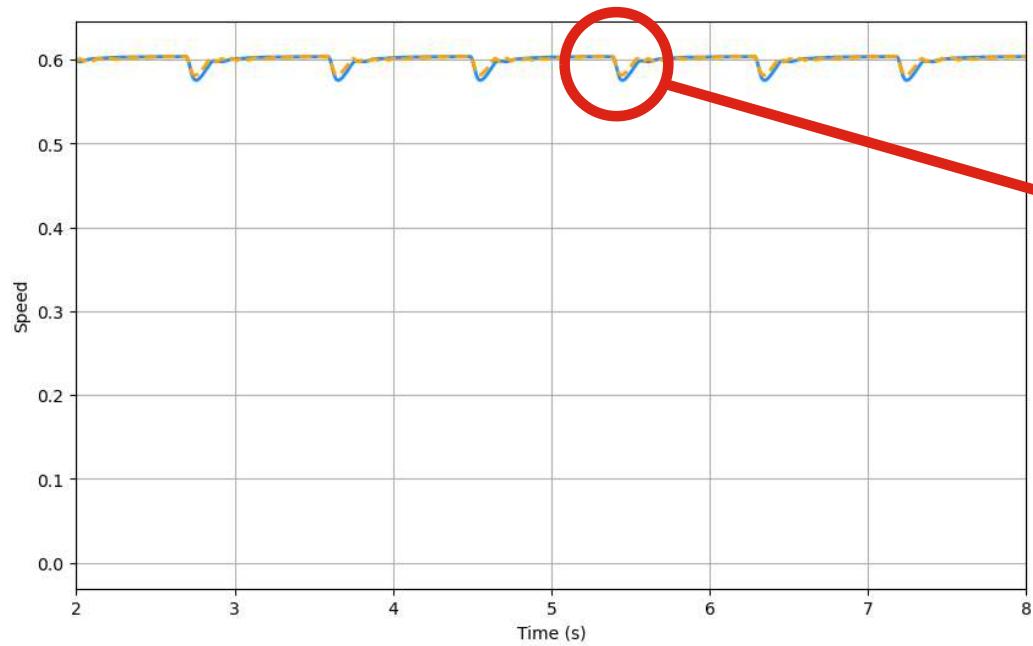
## 속도 RL 제어 - 극단적인 부하



속도 RL은 기존 PI와 더해지면서 외부 부하에 대한 보상의 역할을 수행한다. 관성이 10배 증가하고, 외부 토크가  $-1\text{N}/\text{m}$  주어졌을 때 결과는 위와 같다.



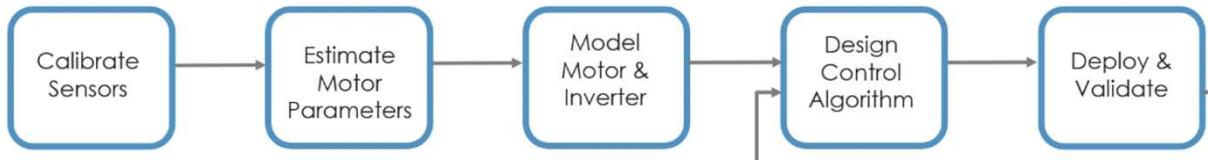
## 속도 RL 제어 - 순간적인 부하



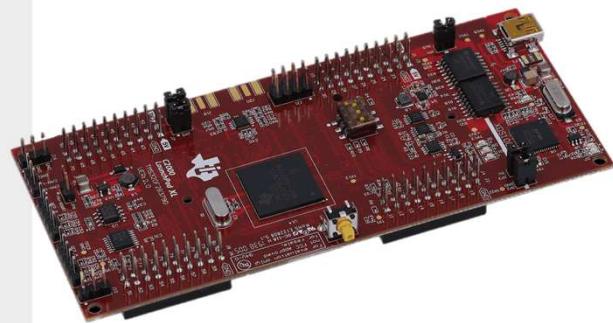
29%정도  
약간의 피크 개선

# 간략한 구동

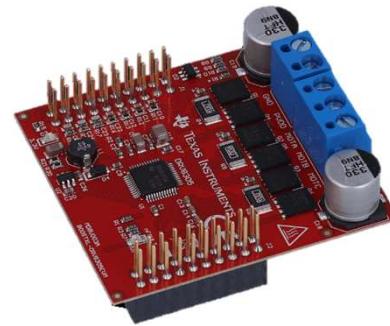
## Workflow



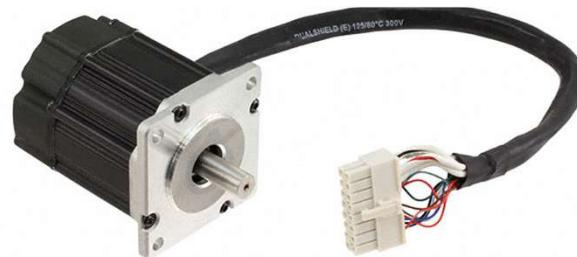
## 간략한 구동



TI LAUNCHXL-F28379D



TI BOOSTXL-DRV8305



TEKNIC M-2310P



## 정리

### **Q. 세탁기의 동적 특성(유동성, 비선형성)에 대응하기 위해 RL을 PI 제어 대신 적용 가능할까?**

#### **전류 제어 시뮬레이션:**

- PI 대신 RL 적용
- 사용 환경에서 관성이 큰 상황을 가정한 후 강건성 검증  
PI만큼의 강건성은 확보하였으나, 주요 특징(주성분 분석 결과)에서는 제한적  
**원인 추정 :** 관성이 너무 커서 RL 정책 반응이 어려움, 하이퍼파라미터 튜닝 부족으로 RL 성능 최적화 미흡

#### **속도 제어 시뮬레이션:**

- PI와 RL을 결합하여 외부 부하 변동에 대한 반응 개선을 확인  
하지만 강건성 확인 하지 못함

#### **결론 및 한계점:**

- RL이 PI를 능가한다고 보기는 어려움 그러나 대체 가능성 존재
- PI, MPC로 모터 속도 제어에 성공했으나, RL 구현이 미흡하여 비교 분석 하지 못함

감사합니다.